

# 实验一：机器学习开发平台搭建与算法测试 实验报告

## 一、实验环境搭建

操作系统：Windows 11 + WSL2 (Ubuntu 24.04)

Python 环境：Python 3.9.25, 使用 uv 管理的虚拟环境（.venv）

GPU 环境：NVIDIA GeForce RTX 3050 Ti Laptop (4GB), CUDA 13.2 驱动 + nvidia-cuda-toolkit 12.0

依赖库清单：

| 类别      | 库名                                     |
|---------|----------------------------------------|
| 科学计算    | numpy, scipy, pandas                   |
| 可视化     | matplotlib, seaborn                    |
| 传统机器学习  | scikit-learn, xgboost, lightgbm        |
| 深度学习    | tensorflow 2.20                        |
| GPU 工具链 | nvidia-cuda-toolkit 12.0, CUDA 驱动 13.2 |

环境搭建遇到的问题与解决：

- Windows PATH 污染 WSL2 环境。** WSL2 自动挂载 Windows C 盘并合并 PATH，导致 TensorFlow 扫描到 Windows 侧 CUDA 13.1 的 `nvlink/ptxas`，与 WSL2 内 CUDA 13.2 驱动冲突。解决：在代码中过滤 `/mnt/c/` 路径。
- 缺少 CUDA 编译工具链。** WSL2 默认只安装显卡驱动，不含 `ptxas`、`nvlink`、`libdevice.10.bc` 等 CUDA 开发文件，TensorFlow XLA 编译器无法编译 GPU kernel。解决：`sudo apt install nvidia-cuda-toolkit` 安装完整 CUDA 12.0 工具链。
- XLA 找不到 libdevice.10.bc。** 系统安装路径 `/usr/lib/nvidia-cuda-toolkit/libdevice/` 不在 XLA 的默认搜索路径中。解决：在实验目录创建软链接 `ln -s /usr/lib/nvidia-cuda-toolkit/libdevice/libdevice.10.bc .`。
- Titanic 数据集下载失败。** HTTPS 代理拦截导致 SSL 错误。解决：改用 seaborn 内置 Titanic 数据集。

## 二、算法实现

实验共实现并测试 9 种算法，涵盖四大类：

| 类别    | 算法                         | 核心参数                                                                          |
|-------|----------------------------|-------------------------------------------------------------------------------|
| 线性模型  | LogisticRegression         | max_iter=1000                                                                 |
| 距离/概率 | KNN (KNeighborsClassifier) | n_neighbors=5                                                                 |
| 距离/概率 | GaussianNB                 | 默认参数                                                                          |
| 树模型   | DecisionTreeClassifier     | max_depth=5                                                                   |
| 树模型   | RandomForestClassifier     | n_estimators=100                                                              |
| 树模型   | AdaBoostClassifier         | n_estimators=50                                                               |
| 树模型   | GradientBoostingClassifier | n_estimators=100                                                              |
| 核方法   | SVM (SVC)                  | kernel='rbf'                                                                  |
| 深度学习  | DNN (Sequential)           | 128→Dropout(0.3)→64→Dropout(0.3)→Softmax, Adam, max 50 epochs + EarlyStopping |


传统算法使用 80/20 训练/测试划分 + StandardScaler 标准化评估。DNN 使用额外的 10% validation split + EarlyStopping + ReduceLROnPlateau。

数据预处理：标准化 + 对 CIFAR-10（3072 维）使用 PCA 降至 200 维控制运算时间。MNIST（784 维）保留全维度。


## 三、实验结果

### 3.1 算法精度对比（各数据集）


Algorithm Performance Comparison - iris



Algorithm Performance Comparison - digits



Algorithm Performance Comparison - mnist




3.2 完整 Accuracy 对比

| 算法                 | iris   | digits | breast_cancer | titanic | mnist  | cifar10 |
|--------------------|--------|--------|---------------|---------|--------|---------|
| KNN                | 0.9333 | 0.9639 | 0.9561        | 0.8268  | 0.8990 | 0.1250  |
| LogisticRegression | 0.9333 | 0.9722 | 0.9825        | 0.8045  | 0.9070 | 0.2030  |
| DecisionTree       | 0.9333 | 0.6694 | 0.9211        | 0.7598  | 0.7100 | 0.1990  |
| NaiveBayes         | 0.9667 | 0.7417 | 0.9298        | 0.7654  | 0.5600 | 0.2370  |
| SVM                | 0.9667 | 0.9750 | 0.9825        | 0.8212  | 0.9360 | 0.2280  |
| RandomForest       | 0.9000 | 0.9639 | 0.9561        | 0.8268  | 0.9470 | 0.2290  |
| AdaBoost           | 0.9333 | 0.7278 | 0.9561        | 0.7821  | 0.6330 | 0.2280  |
| GradientBoosting   | 0.9667 | 0.9528 | 0.9561        | 0.8045  | 0.9340 | 0.2400  |
| DNN                | 0.8333 | 0.9639 | 0.9649        | 0.8212  | 0.9420 | 0.1960  |

3.2 训练时间对比（秒）

| 算法                 | iris  | digits | breast_cancer | titanic | mnist (784维) | cifar10 (200维) |
|--------------------|-------|--------|---------------|---------|--------------|----------------|
| KNN                | 0.001 | 0.001  | 0.001         | 0.001   | 0.002        | 0.002          |
| LogisticRegression | 0.002 | 0.097  | 0.006         | 0.004   | 1.434        | 0.668          |
| DecisionTree       | 0.001 | 0.011  | 0.006         | 0.001   | 0.492        | 0.354          |
| NaiveBayes         | 0.001 | 0.002  | 0.001         | 0.001   | 0.048        | 0.006          |
| SVM                | 0.002 | 0.202  | 0.008         | 0.040   | 8.887        | 5.968          |
| RandomForest       | 0.087 | 0.241  | 0.140         | 0.127   | 5.080        | 5.153          |
| AdaBoost           | 0.050 | 0.152  | 0.118         | 0.064   | 3.947        | 3.714          |
| GradientBoosting   | 0.205 | 5.411  | 0.453         | 0.109   | 157.5        | 154.0          |
| DNN (GPU)          | 11.03 | 11.42  | 8.80          | 7.01    | 30.69        | 19.65          |



3.4 各数据集最佳算法

| 数据集              | 样本数  | 特征数      | 类别数 | 最佳算法                     | Accuracy | F1     |
|------------------|------|----------|-----|--------------------------|----------|--------|
| iris             | 150  | 4        | 3   | NaiveBayes / SVM / GBDT  | 0.9667   | 0.9666 |
| digits           | 1797 | 64       | 10  | SVM                      | 0.9750   | 0.9749 |
| breast_cancer    | 569  | 30       | 2   | LogisticRegression / SVM | 0.9825   | 0.9825 |
| titanic          | 891  | 10       | 2   | KNN / RandomForest       | 0.8268   | 0.8255 |
| mnist            | 5000 | 784      | 10  | RandomForest             | 0.9470   | 0.9472 |
| cifar10 (PCA200) | 5000 | 3072→200 | 10  | GradientBoosting         | 0.2400   | 0.2346 |

---

四、结果分析

1. 小规模标准数据集（iris、breast\_cancer、digits）：所有算法表现优秀（acc > 90%）。
- iris（150 样本，4 维）：NaiveBayes / SVM / GBDT 并列 96.67%。DNN 最差（83.33%），因为 150 个样本对神经网络太少。

- breast\_cancer (569 样本, 30 维) : LogisticRegression 和 SVM 并列 98.25%, 线性可分性很好。
- digits (1797 样本, 64 维) : SVM 最佳 97.50%。DecisionTree (66.94%) 和 NaiveBayes (74.17%) 偏低, 特征间存在强关联。

2. Titanic (891 样本, 10 维) : 各算法差异不大 (76%–83%) , 数据信号本身是上限。

3. MNIST (784 维, 全维度) : 去掉 PCA 后准确率飙升。

| 算法           | PCA 100 维 | 全量 784 维      | 提升     |
|--------------|-----------|---------------|--------|
| KNN          | 0.1680    | 0.8990        | +73.1% |
| SVM          | 0.4830    | 0.9360        | +45.3% |
| RandomForest | 0.5960    | <b>0.9470</b> | +35.1% |
| DNN          | 0.4850    | 0.9420        | +45.7% |

784 维全量 + RandomForest 达到 94.70%, 说明图像数据的信息损失与维度压缩成正相关。

4. CIFAR-10 (PCA 200 维) : 最高仅 24%。 3072 维降到 200 维损失了过多空间信息。该任务应使用 CNN 从原始图像学习, PCA 线性降维不适用于自然图像。

5. 训练时间: GradientBoosting 在大规模数据上极慢 (MNIST/CIFAR-10 \~150s) , 因其串行训练 100 棵树的代价高。DNN 利用 GPU 加速稳定在 10–30s。KNN/NaiveBayes 训练几乎瞬时。

---

## 五、实验总结

关键技术难点:

1. WSL2 环境下 CUDA 工具链的完整配置是最大障碍: 驱动安装、Toolkit 安装、XLA 编译器路径对齐三者缺一不可。
2. 高维数据使用 PCA 降维必须平衡信息保留和计算效率——MNIST 从 100→784 维带来 35%–73% 的提升, 说明过度降维也代价巨大。

收获:

1. 建立了一套标准化的 ML 算法对比流程: 数据加载 → 预处理 → 多算法评估 → 可视化 → 分析总结。
2. 直观理解"没有银弹"——不同算法在不同数据特性上各有优势, 特征工程 (PCA 决策) 对最终结果的影响不亚于算法选择。

改进方向:

1. CIFAR-10 应使用 CNN 而非 PCA+传统分类器。
2. 补全 Windows 原生环境测试获取跨平台对比数据。
3. 增加 GridSearchCV 超参数搜索让算法在最优参数下比较。
4. 记录 GPU 显存和系统内存使用完善资源消耗评估。